

Sistema de Recomendação Inteligente para Marketplaces

Enrico Minto Spanier; RA: 10419775

Guilherme Vecchi Bonotti Freitas Silveira; RA: 10418517

Alexandre Luppi Severo e Silva; RA: 10419724

¹Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie
São Paulo – SP – Brasil

{enrico.spanier, alexandre.luppi.silva, guilherme.silveira}@mackenzista.com.br

Abstract. *This project aims to apply artificial intelligence techniques in marketplaces to provide personalized product recommendations, improving the user's shopping experience. The motivation lies in the need to make product search more practical and intuitive. The justification is based on the positive impact of intelligent recommendations, both in increasing sales and enhancing customer loyalty. The main problem addressed is the difficulty users face in finding relevant products among a wide variety of options. The proposed solution seeks to reduce browsing time, increase customer satisfaction, and improve marketplace efficiency.*

Resumo. *Nosso projeto tem como objetivo aplicar técnicas de inteligência artificial em marketplaces para oferecer recomendações personalizadas de produtos, facilitando a jornada de compra dos usuários. A motivação está na necessidade de aprimorar a experiência do consumidor, tornando a busca por itens mais prática e intuitiva. A justificativa baseia-se no impacto positivo dessas recomendações, tanto no aumento das vendas quanto na fidelização de clientes. O problema central é a dificuldade dos usuários em encontrar produtos relevantes diante da grande variedade disponível. A solução proposta busca reduzir o tempo de navegação, aumentar a satisfação do consumidor e contribuir para maior eficiência do marketplace.*

1. Introdução

A pesquisa em questão tem como foco a aplicação de técnicas de inteligência artificial em plataformas de marketplace, com o objetivo de aprimorar a experiência do usuário por meio de recomendações personalizadas de produtos. Em um cenário caracterizado pela ampla variedade de itens disponíveis e pelo crescimento constante do comércio digital, torna-se cada vez mais desafiador para os consumidores encontrar produtos que atendam às suas necessidades de forma rápida e eficiente. Nesse contexto, a utilização de sistemas inteligentes surge como uma solução promissora para tornar a jornada de compra mais intuitiva, reduzindo o tempo de navegação e aumentando a relevância das sugestões apresentadas. Além disso, tais abordagens contribuem significativamente para o aumento das vendas e a fidelização dos clientes, ao mesmo tempo em que promovem maior eficiência operacional nos marketplaces.

Para guiar o desenvolvimento deste trabalho, o presente relatório está estruturado da seguinte forma: a Seção 2 apresenta a Fundamentação Teórica, abordando conceitos

essenciais de Aprendizado Profundo e Sistemas de Recomendação. A Seção 3 detalha a Metodologia adotada, descrevendo a base de dados, a análise exploratória inicial e o pipeline técnico do modelo. A Seção 4 discute as implicações éticas e os resultados parciais obtidos, além do cronograma de próximas etapas. Por fim, a Seção 5 expõe as Referências Bibliográficas que embasaram esta pesquisa.

2. Fundamentação Teórica

A fundamentação teórica deste projeto concentra-se no uso de *Deep Learning*, uma subárea do aprendizado de máquina que utiliza redes neurais artificiais profundas para modelar padrões complexos em grandes volumes de dados [2]. Inspiradas no funcionamento biológico, essas redes são compostas por múltiplas camadas ocultas que permitem a extração hierárquica de características, tornando-as eficazes em tarefas de previsão e recomendação de alta dimensionalidade.

No contexto de marketplaces, sistemas de recomendação tradicionais baseavam-se majoritariamente em Filtragem Colaborativa e Filtragem Baseada em Conteúdo [4]. Contudo, abordagens contemporâneas utilizam redes neurais profundas (*Deep Neural Networks* - DNNs) para mitigar problemas clássicos como a inicialização a frio (*cold-start*) e a esparsidade dos dados [5]. Modelos baseados em Redes Neurais Recorrentes (RNNs) ou arquiteturas de *Transformers* são aplicados para identificar padrões temporais e comportamentais do usuário ao longo de suas sessões de navegação.

Outro conceito basilar é o uso de *embeddings*, que consistem na representação de usuários e produtos como vetores numéricos de baixa dimensionalidade em um espaço contínuo [1]. Essa técnica possibilita calcular de forma eficiente a similaridade de cosseno entre diferentes itens e perfis de consumo, refinando a precisão das sugestões geradas em tempo real.

3. Metodologia

A metodologia deste projeto estrutura-se a partir de um pipeline experimental focado na engenharia de dados e modelagem preditiva profunda.

3.1. Base de Dados Utilizada e Análise Exploratória

Para o desenvolvimento do sistema, foi selecionada a base de dados pública *Brazilian E-Commerce Public Dataset by Olist* [3], disponível na plataforma Kaggle. O dataset compreende dados reais de aproximadamente 100 mil pedidos realizados entre 2016 e 2018 em múltiplos marketplaces no Brasil.

Visando compreender a distribuição dos dados e garantir a consistência das entradas para o modelo, realizou-se uma análise estatística descritiva inicial. A Tabela 1 apresenta as métricas quantitativas estruturais das principais entidades do conjunto de dados.

Além dos dados tabulares de volume, identificou-se uma esparsidade acentuada na matriz de interações usuário-item, justificando a necessidade de aplicar arquiteturas de *Deep Learning* baseadas em *embeddings* para comprimir e aproximar essas relações latentes.

Tabela 1. Estatísticas descritivas do dataset Olist.

Métrica de Controle	Valor Quantitativo
Número Total de Pedidos	99.441
Clientes Únicos Cadastrados	96.096
Produtos Distintos no Catálogo	32.951
Total de Avaliações (<i>Reviews</i>)	100.000
Período Temporal Analisado	2016 – 2018

3.2. Pipeline Técnico e Modelagem

O fluxo de processamento técnico seguirá as seguintes etapas sequenciais: 1. **Tratamento e Limpeza:** Eliminação de registros nulos e normalização de variáveis numéricas de preço e frete. 2. **Construção de Embeddings:** Mapeamento das chaves alfa-numéricas de `customer_id` e `product_id` em vetores densos através de uma camada *Embedding* inicial utilizando a biblioteca TensorFlow/Keras. 3. **Arquitetura do Modelo:** Implementação de uma rede neural híbrida combinando uma estrutura *Wide* (para memorização de regras de filtragem baseada em conteúdo) e *Deep* (para generalização de novos padrões). 4. **Métricas de Avaliação:** O desempenho será mensurado por meio de métricas de classificação e *ranking*, especificamente a *Root Mean Squared Error* (RMSE) para predição de notas de avaliação e *Mean Average Precision* (MAP) para a lista de recomendação final.

4. Ética, Resultados Parciais e Cronograma

4.1. Discussão Ética

A aplicação de algoritmos de aprendizado profundo sobre históricos de compras exige conformidade com as diretrizes da Lei Geral de Proteção de Dados (LGPD). Todos os identificadores pessoais do dataset foram previamente anonimizados na origem [3]. Adicionalmente, o desenvolvimento atenta-se para evitar o fenômeno da "bolha de filtragem" (*filter bubble*), inserindo fatores de aleatoriedade (*serendipity*) no algoritmo para garantir a diversidade e mitigar vieses de recomendação que monopolizem o tráfego em poucos produtos.

4.2. Resultados Parciais e Repositório

No estágio atual do projeto, foram concluídas as fases de ingestão de dados e análise exploratória estrutural. A arquitetura inicial da rede neural encontra-se em fase de prototipagem e validação local.

O código-fonte integral, scripts de preparação de dados e as próximas atualizações estão sendo versionados e documentados em ambiente aberto. O repositório oficial do projeto pode ser acessado de forma direta através do link: <https://github.com/andydragonn/Sistema-de-Recomenda-o-Inteligente-para-Marketplaces-07P>.

4.3. Próximas Etapas

Para garantir a conclusão dos objetivos propostos alinhados à entrega final, as atividades subsequentes foram delimitadas de acordo com o cronograma técnico apresentado na

Tabela 2.

Tabela 2. Cronograma planejado para as próximas etapas do projeto.

Etapa	Descrição Técnica da Atividade	Período Estimado
1	Finalização da engenharia de atributos e geração de matrizes	Semanas 1 - 2
2	Treinamento da rede neural (<i>Wide & Deep</i>) e ajuste de hiperparâmetros	Semanas 3 - 4
3	Avaliação do modelo através de métricas de acurácia e perda	Semana 5
4	Consolidação dos resultados finais e escrita do relatório conclusivo	Semana 6

Referências

- [1] Covington, P., Adams, J., and Sargin, E. (2016). Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems*, pages 191–198.
- [2] Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. Available at <http://www.deeplearningbook.org>.
- [3] Olist (2018). Brazilian E-Commerce Public Dataset by Olist. *Kaggle Repository*. Available at <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data>. Accessed: May 2026.
- [4] Resnick, P. and Varian, H. R. (1997). Recommender systems. *Communications of the ACM*, 40(3):56–58.
- [5] Zhang, S., Yao, L., Sun, A., and Tay, Y. (2019). Deep learning based recommender system: A survey and a new perspective. *ACM Computing Surveys (CSUR)*, 52(1):1–38.