

Sistema de Recomendação Inteligente para Marketplaces

Enrico Minto Spanier; RA: 10419775

Guilherme Vecchi Bonotti Freitas Silveira; RA: 10418517

Alexandre Luppi Severo e Silva; RA: 10419724

¹Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie
São Paulo – SP – Brasil

{enrico.spanier, alexandre.luppi.silva, guilherme.silveira}@mackenzista.com.br

Abstract. *This project applies Deep Learning techniques to a marketplace dataset to provide personalized product recommendations. Using the Olist dataset, we implemented an embedding-based neural network to predict user ratings. The results show that while data sparsity presents a challenge for absolute error minimization, the model effectively ranks products for individual users. The ethical implications of algorithmic recommendation systems were also discussed, and the solution was designed to preserve user privacy through the exclusive use of anonymized data.*

Resumo. *Este projeto aplica técnicas de Deep Learning em um dataset de marketplace para oferecer recomendações personalizadas de produtos. Utilizando a base pública da Olist, disponível no Kaggle, implementamos uma rede neural baseada em embeddings para prever notas de avaliação de usuários. Os resultados mostram que, embora a esparsidade dos dados seja um desafio para a minimização do erro absoluto, o modelo é eficaz em ranquear produtos para usuários individuais, cumprindo o objetivo central do sistema. As implicações éticas do uso da IA em sistemas de recomendação também foram discutidas ao longo do trabalho.*

1. Introdução

1.1. Contextualização

O comércio eletrônico brasileiro tem crescido de forma expressiva nos últimos anos, impulsionado pela digitalização dos hábitos de consumo e pela expansão de plataformas de marketplace. Nesse cenário, a quantidade de produtos disponíveis para os consumidores é vastíssima, tornando cada vez mais difícil para o usuário encontrar itens alinhados às suas preferências sem auxílio tecnológico. Sistemas de recomendação surgem como solução a esse problema, filtrando o catálogo de produtos e apresentando ao usuário aqueles com maior probabilidade de agrado [4].

1.2. Justificativa

A personalização da experiência de compra é um dos principais fatores de diferenciação competitiva em plataformas de e-commerce. De acordo com estudos recentes, recomendações personalizadas podem aumentar significativamente a taxa de conversão e o tempo de permanência do usuário na plataforma [5]. Apesar disso, muitas soluções existentes ainda se baseiam em métodos estatísticos simples, como filtragem colaborativa

baseada em similaridade de cosseno, que não capturam adequadamente padrões complexos de comportamento. O uso de *Deep Learning* com *embeddings* representa uma alternativa mais robusta e escalável.

1.3. Objetivo

O objetivo deste projeto é desenvolver um sistema de recomendação inteligente baseado em *Deep Learning* capaz de sugerir produtos relevantes para usuários de uma plataforma de marketplace. Para isso, utilizamos o dataset público da Olist [3], aplicando uma rede neural com *embeddings* para modelar a relação entre usuários e produtos a partir das avaliações históricas.

1.4. Opção do Projeto

Este projeto enquadra-se na **Opção ML/DL** (Machine Learning / Deep Learning), conforme definido no enunciado da disciplina, uma vez que emprega uma rede neural profunda para resolver um problema de predição e ranqueamento sobre uma base de dados pública.

2. Fundamentação Teórica

2.1. Deep Learning e Embeddings

A base técnica deste projeto é o uso de *Deep Learning* e *embeddings* [2]. *Embeddings* são representações vetoriais densas de baixa dimensionalidade que codificam entidades discretas — como usuários e produtos — em um espaço matemático contínuo. Nesse espaço, entidades semanticamente similares ficam geometricamente próximas, permitindo que o modelo identifique preferências sem a necessidade de definir regras manuais [1].

Em sistemas de recomendação modernos, a concatenação dos vetores de *embedding* de usuário e produto é passada por camadas densas que aprendem a prever a avaliação que aquele usuário daria ao produto. Esse paradigma, conhecido como *Neural Collaborative Filtering*, superou métodos clássicos como a decomposição matricial em múltiplos benchmarks [5].

2.2. Filtragem Colaborativa

A filtragem colaborativa é a técnica precursora dos sistemas de recomendação modernos [4]. Ela parte do princípio de que usuários com comportamentos similares no passado tendem a ter preferências similares no futuro. Em sua versão baseada em modelo, a decomposição em valores singulares (SVD) é usada para fatorar a matriz de avaliações em representações latentes de usuários e itens — conceito que os *embeddings* neurais generalizam de forma mais flexível.

2.3. Trabalhos Relacionados

Covington et al. (2016) [1] propuseram um sistema de recomendação em duas etapas para o YouTube, utilizando redes neurais profundas. Na primeira etapa, candidatos relevantes são selecionados de um catálogo de milhões de vídeos; na segunda, um modelo de ranqueamento os ordena. Os autores demonstraram que *embeddings* de IDs de usuários e histórico de visualizações superam abordagens baseadas em fatores latentes lineares.

Zhang et al. (2019) [5] realizaram uma revisão abrangente sobre sistemas de recomendação baseados em *Deep Learning*, categorizando as arquiteturas em modelos baseados em MLP, autoencoders, redes convolucionais, recorrentes e de atenção. Os autores identificam que a principal vantagem do *Deep Learning* sobre métodos tradicionais é a capacidade de capturar interações não-lineares entre usuários e itens.

Resnick e Varian (1997) [4] introduziram formalmente o conceito de sistemas de recomendação, descrevendo os fundamentos da filtragem colaborativa. Apesar de datado, o trabalho é a referência seminal da área e contextualiza a evolução dos métodos até as abordagens neurais atuais.

Em comparação com esses trabalhos, a solução proposta neste projeto é mais simples em escala, porém aplica os mesmos princípios de *embeddings* e ranqueamento sobre um dataset real de e-commerce brasileiro.

3. Metodologia e Resultados Esperados

3.1. Abordagem e Etapas

O pipeline do projeto foi dividido em duas grandes etapas, correspondendo aos dois bimestres da disciplina:

1. **N1 — Análise Exploratória e Preparação dos Dados:** carregamento e limpeza do dataset, análise da distribuição de avaliações, identificação de desequilíbrios nos dados e codificação de IDs de usuários e produtos em índices numéricos.
2. **N2 — Modelagem e Avaliação:** construção e treinamento da rede neural com TensorFlow/Keras, avaliação das métricas de erro (MSE) no conjunto de treino e validação, e geração de listas de recomendação personalizadas para usuários específicos.

Os resultados esperados eram: (a) um modelo capaz de prever notas com erro quadrático médio (MSE) razoável e (b) um sistema de ranqueamento funcional que ordenasse produtos não adquiridos pelo usuário de forma personalizada.

3.2. Dataset

Utilizamos o **Brazilian E-Commerce Public Dataset by Olist** [3], disponível publicamente no Kaggle. O dataset contém informações reais anonimizadas de mais de 100.000 pedidos realizados entre 2016 e 2018 em múltiplos marketplaces brasileiros. Para este projeto, foram utilizadas as seguintes colunas extraídas da junção de tabelas do dataset:

- `customer_unique_id`: identificador anônimo do cliente (usado como ID de usuário).
- `product_id`: identificador único do produto.
- `review_score`: nota de avaliação do produto pelo cliente, em escala de 1 a 5.

Os IDs textuais foram convertidos em índices inteiros para uso nas camadas de *embedding*. Registros com valores nulos foram removidos. O dataset final contém aproximadamente 96.000 interações usuário-produto após a limpeza. Os dados foram divididos em 80% para treino e 20% para validação.

4. Resultados

4.1. Análise Exploratória dos Dados e Arquitetura

A análise inicial (Figura 1) revelou um desequilíbrio acentuado nas avaliações, com predominância de notas máximas (nota 5), o que caracteriza um dataset com distribuição assimétrica positiva — fenômeno comum em plataformas de e-commerce, onde usuários satisfeitos tendem a avaliar mais. Os 10 produtos mais vendidos foram identificados e listados por número de avaliações.




Figura 1. Distribuição de avaliações e popularidade de itens (Notebook 1).

A arquitetura implementada (Figura 2) utilizou duas camadas de *Embedding* (uma para usuários e uma para produtos), com dimensão 50 cada, seguidas de achatamento (*Flatten*), concatenação dos vetores e três camadas densas (128, 64 e 1 neurônios). O modelo totalizou mais de 6,5 milhões de parâmetros treináveis, compatível com o tamanho do vocabulário de usuários e produtos no dataset.

Model: "functional"

Layer (type)	Output Shape	Param #	Connected to
user_input (InputLayer)	(None, 1)	0	-
item_input (InputLayer)	(None, 1)	0	-
user_embedding (Embedding)	(None, 1, 50)	4,895,850	user_input[0][0]
item_embedding (Embedding)	(None, 1, 50)	1,639,450	item_input[0][0]
user_flatten (Flatten)	(None, 50)	0	user_embedding[0][0]
item_flatten (Flatten)	(None, 50)	0	item_embedding[0][0]
concatenate (Concatenate)	(None, 100)	0	user_flatten[0][0] item_flatten[0][0]
dense (Dense)	(None, 128)	12,928	concatenate[0][0]
dense_1 (Dense)	(None, 64)	8,256	dense[0][0]
dense_2 (Dense)	(None, 1)	65	dense_1[0][0]

Total params: 6,556,549 (25.01 MB)
Trainable params: 6,556,549 (25.01 MB)
Non-trainable params: 0 (0.00 B)

Figura 2. Arquitetura da Rede Neural (Notebook 2).

4.2. Treinamento e Predição

O modelo foi treinado por 30 épocas com o otimizador Adam e função de perda MSE. A Figura 3 demonstra a convergência do erro de treino ao longo das épocas, enquanto o erro de validação, embora superior ao de treino, manteve-se estável sem divergir, indicando ausência de *overfitting* severo. A Figura 4 ilustra a saída prática do sistema: uma lista ordenada das 3 principais sugestões para o Usuário 100.




Figura 3. Histórico de perda (MSE) durante o treinamento.

```
# Simulação para o Usuário de ID = 100
target_user = 100

# Pegamos uma amostra de produtos que ele ainda não comprou (aqui simulado com os primeiros 50 produtos)
sample_products = np.arange(0, 50)
user_array = np.array([target_user] * len(sample_products))

# Prevendo as notas
predicted_ratings = model.predict([user_array, sample_products])

# Combinando e ordenando para pegar as top 3 recomendações
recomendacoes = pd.DataFrame({
    'Produto_Id': sample_products,
    'Nota_Prevista': predicted_ratings.flatten()
})

top_3 = recomendacoes.sort_values(by='Nota_Prevista', ascending=False).head(3)

print("\n--- TOP 3 RECOMENDAÇÕES PARA O USUÁRIO 100 ---")
print(top_3)
```

... 2/2 ————— 0s 31ms/step

```
--- TOP 3 RECOMENDAÇÕES PARA O USUÁRIO 100 ---
   Produto_Id  Nota_Prevista
22          22         4.248129
41          41         4.242416
36          36         4.193106
```

Figura 4. Exemplo de saída: Top 3 recomendações para o Usuário 100.

4.3. Aspectos Éticos e Responsabilidade no Uso da IA

O desenvolvimento de sistemas de recomendação baseados em dados de comportamento de usuários suscita importantes questões éticas. Neste projeto, os seguintes aspectos foram considerados:

Privacidade dos dados: O dataset utilizado é público e seus identificadores de usuário e produto são anonimizados, de forma que nenhuma informação pessoal identificável foi processada ou exposta em nenhuma etapa do projeto.

Viés algorítmico: O desequilíbrio nas avaliações (predominância de notas 5) pode introduzir viés no modelo, fazendo com que ele tenda a superestimar avaliações para todos os usuários. Esse viés foi identificado na análise exploratória, mas não foi corrigido nesta versão do modelo — o que constitui uma limitação a ser endereçada em trabalhos futuros.

Efeito de câmara de eco (*echo chamber*): Sistemas de recomendação podem reforçar preferências já existentes, reduzindo a diversidade de produtos apresentados ao usuário. Embora não implementado, mecanismos de diversificação das listas de recomendação (como penalidade de similaridade) poderiam mitigar esse efeito.

Transparência: O modelo desenvolvido, por ser baseado em *embeddings* e redes densas, tem interpretabilidade limitada. Em aplicações reais, técnicas de explicabilidade de IA (*Explainable AI*) deveriam ser adotadas para garantir que os usuários possam compreender os critérios de recomendação.

4.4. Endereços do Projeto

GitHub: O código-fonte, notebooks e dataset estão disponíveis em: <https://github.com/INSERIR-LINK-DO-REPOSITORIO>

Vídeo (YouTube): A apresentação em vídeo do projeto está disponível em: <https://www.youtube.com/watch?v=INSERIR-LINK-DO-VIDEO>

5. Conclusão

Este projeto demonstrou a viabilidade da aplicação de *Deep Learning* com *embeddings* para a construção de um sistema de recomendação em um contexto real de marketplace.

Utilizando o dataset público da Olist, foi possível construir um modelo capaz de aprender representações latentes de usuários e produtos a partir de avaliações históricas e, com base nessas representações, ranquear produtos não adquiridos de forma personalizada para cada usuário.

O objetivo central do projeto foi atingido: o sistema é capaz de gerar listas de recomendação coerentes para usuários individuais. O principal desafio identificado foi a esparsidade dos dados — muitos usuários realizaram apenas uma compra no período coberto pelo dataset, caracterizando o problema do *cold start*, que limita a qualidade das recomendações para esse perfil de usuário.

Como contribuições obtidas, destacam-se: (a) a implementação completa de um pipeline de recomendação baseado em *Deep Learning*, do pré-processamento à predição; (b) a discussão dos aspectos éticos associados ao uso de IA em sistemas de recomendação; e (c) a análise crítica das limitações do modelo, abrindo caminho para trabalhos futuros que incorporem técnicas de mitigação de vies, diversificação de recomendações e tratamento do *cold start*.

6. Referências Bibliográficas

Referências

- [1] Covington, P., Adams, J., and Sargin, E. (2016). Deep neural networks for youtube recommendations. In *Proceedings of the 10th ACM Conference on Recommender Systems*, pages 191–198.
- [2] Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. Available at <http://www.deeplearningbook.org>.
- [3] Olist (2018). Brazilian E-Commerce Public Dataset by Olist. *Kaggle Repository*. Available at <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data>. Accessed: May 2026.
- [4] Resnick, P. and Varian, H. R. (1997). Recommender systems. *Communications of the ACM*, 40(3):56–58.
- [5] Zhang, S., Yao, L., Sun, A., and Tay, Y. (2019). Deep learning based recommender system: A survey and a new perspective. *ACM Computing Surveys (CSUR)*, 52(1):1–38.